

WiFi CSI를 활용한 유니티 실내 신원 식별 시스템



202255656 김민현 guncraft11@gmail.com

202325195 김민경 a33392346@gmail.com

202355543 박한별 istar23@pusan.ac.kr

지도교수: 김종덕

목 차

1. 서론	1
1.1. 연구 배경	1
1.2. 기존 문제점	2
1.3. 연구 목표	2
2. 연구 배경	3
2.1. 무선통신과 Wi-Fi	3
2.1.1. 무선통신과 주파수 대역	3
2.1.2. Wi-Fi 통신 구조	3
2.1.3. 다중경로 전파	4
2.2. CSI	4
2.3. ESP32-c6	5
2.3.1. 특징	5
2.3.2. 패킷 전송 방식	5
2.3.3. CSI 데이터 추정 방식	8
2.4. 전처리	9
2.4.1. Window Sliding	9
2.5. 시각화 / 평가	9
2.5.1. Confusion Matrix / Heatmap	9
2.5.2. 그래프	10
2.5.3. RMSE	10
2.6. PCA	11
2.7. KNN Classification	12
2.8. CNN	13
3. 연구 내용	14
3.1. 시나리오1: 단일 송수신기 환경에서 CSI 분석	14
3.1.1. 시나리오1-1: 사람 & 위치 식별 가능성 확인	14
3.1.1.1. 시나리오1-1 실험 목적	14

3.1.1.2. 시나리오1-1 실험 환경	14
3.1.1.3. 시나리오1-1 실험 데이터	16
3.1.1.4. 시나리오1-1 데이터 전처리 및 사용 모델	17
3.1.1.5. 시나리오1-1 사람 식별 가능성 확인 결과	19
3.1.2. 시나리오1-2: 사람 & 위치 식별 시도	21
3.1.2.1. 시나리오1-2 실험 목적	21
3.1.2.2. 시나리오1-2 데이터 전처리 및 사용 모델	21
3.1.2.3. 시나리오1-2 사람 & 위치 식별 시도 결과	22
3.1.3. 시나리오1-3: 1인 데이터 합성 시도	24
3.1.3.1. 시나리오1-3 실험 목적	24
3.1.3.2. 시나리오1-3 단순 덧셈 연산을 통한 1인 데이터 합성	24
3.1.3.3. 시나리오1-3 배경 차감을 통한 1인 데이터 합성	26
3.1.3.4. 시나리오1-3 1인 데이터 합성 시도 결과	28
3.1.4. 시나리오1-4: 2인 데이터 분리 시도	29
3.1.4.1. 시나리오1-4 실험 목적	29
3.1.4.2. 시나리오1-4 2인 데이터 분리	29
3.1.4.3. 시나리오1-4 2인 데이터 분리 시도 결과	29
3.1.5. 시나리오1-5: 비동일 날짜 CSI 데이터 학습 시도	30
3.1.5.1. 시나리오1-5 실험 목적	30
3.1.5.2. 시나리오1-5 비동일 날짜 CSI 데이터 학습	30
3.1.5.3. 시나리오1-5 비동일 날짜 CSI 데이터 학습 시도 결과	30
3.1.6. 시나리오1 결과	31
3.2. 시나리오2: 다중 송수신기 환경에서 CSI 분석	32
3.2.1. 시나리오2-1: 사람 & 위치 식별 시도	32
3.2.1.1. 시나리오2-1 실험 목적	32
3.2.1.2. 시나리오2-1 실험 환경	32
3.2.1.3. 시나리오2-1 실험 데이터	34
3.2.1.4. 시나리오2-1 사람 & 위치 식별 시도 결과	35
3.2.2. 시나리오2-2: KNN을 사용한 2인 데이터 합성 & 분리 시도	36
3.2.2.1. 시나리오2-2 실험 목적	36

3.2.2.2. 시나리오2-2 배경 차감을 통한 1인 데이터 합성 시도	36
3.2.2.3. 시나리오2-2 호흡수 분석을 통한 2인 데이터 합성 & 분리 시도	37
3.2.3. 시나리오2-3: 딥러닝을 활용한 2인 데이터 합성 & 분리 시도	38
3.2.3.1. 시나리오2-3 실험 목적	38
3.2.3.2. 시나리오2-3 2D CNN 합성/분리	38
3.2.3.3. 시나리오2-3 2D CNN Dual Network	39
3.2.3.4. 시나리오2-3 2D CNN Dual Network + Cycle	41
3.2.3.5. 시나리오2-3 2D CNN Dual Network + Cycle + 4-Rx	43
3.2.3.6. 시나리오2-3 1D CNN Dual Network + Cycle + 4-Rx	45
3.2.4. 시나리오2 결과	47
3.3. 유니티 실내 신원 식별 시스템 개발	47
3.3.2. 시스템 아키텍처	49
3.3.3. 신호 동기화 및 전처리	49
3.3.4. 식별 추론	50
3.3.5. 3D 실시간 시각화	50
3.3.6. 유스케이스 다이어그램	50
3.3.7. 시퀀스 다이어그램	50
3.3.8. 시연 결과	50
4. 연구 결과 분석 및 평가	52
4.1 시나리오 1 결과 분석	52
4.2 시나리오 2 결과 분석	52
4.2.1 기존 방법을 이용한 분석	52
4.2.2 딥러닝을 이용한 분석	53
4.3 종합 평가	53
5. 결론 및 향후 연구 방향	53
5.1 결론	53
5.2 향후 연구 방향	54
6. 참고 문헌	54

1. 서론

1.1. 연구 배경

최근 스마트 홈, 스마트 헬스케어, 실내 보안 시스템 등 다양한 분야에서 사람의 위치나 상태 등을 비접촉 방식으로 인식하는 기술에 대한 관심이 증가하고 있다. 그중에서도 무선 신호가 공간을 이동하며 환경적 요인에 의해 변형되는 특성을 담고 있는 CSI(Channel State Information)를 활용한 Wi-Fi 센싱 기술이 큰 주목을 받고 있다. CSI를 활용하면 별도의 웨어러블 장비나 센서가 없어도 행동 인식 및 사용자 식별, 위치 추적 및 경로 파악 등의 기능을 수행할 수 있다.

최근에는 ESP 기반 장치를 이용하여 비교적 저비용으로 CSI 데이터를 수집할 수 있게 되었으며 여기에 머신러닝이나 딥러닝 기술을 적용하여 CSI 데이터 패턴을 분석하는 연구가 활발하게 진행되고 있다. 따라서 본 연구에서는 ESP 기반 장치를 활용하여 수집한 Wi-Fi CSI 데이터를 기반으로 다중 사용자 환경에서의 사람 수 추정(Human Counting), 구역 위치 인식(Localization), 개인 식별(Identification)을 동시에 수행할 수 있는 유니티 기반 통합 실내 센싱 시스템을 구현하고자 한다.



Fig. 1-1 : The flowchart of Wi-Fi sensing working principle 1 (Input → Signal Processing & Algorithm → Applications). Source: Lumenci (February 2023).




Fig. 1-2 : The flowchart of Wi-Fi sensing working principle 2 (Input → Signal Processing & Algorithm → Applications). Source: Lumenci (February 2023).

1.2. 기존 문제점

기존의 카메라 기반 시스템은 정확도는 높지만 조명 환경이나 장애물 등에 가려지는 시야 제한의 영향을 받는다. 또한 경우에 따라서는 촬영에 따른 개인정보 침해 문제가 발생할 수 있다.

이러한 문제를 해결하기 위한 기존의 **Wi-Fi** 센싱 연구들 역시 대부분 단일 사용자를 기준으로 특정 기능만 수행하는 경우가 많았다. 한 사람의 위치를 추정 하거나 특정 사용자를 식별하는 단일 목적만을 중심으로 하는 연구가 주로 이루어 졌으며 실제 환경처럼 여러 사용자가 동시에 존재하는 상황을 충분히 반영하지 못한다는 한계가 존재했다. 실제 실내 환경에서는 사용자 수 변화, 위치 이동, 사용자 구분이 동시에 요구되기 때문에 보다 통합적인 센싱 기술이 필요할 것으로 보인다.

1.3. 연구 목표

본 연구에서는 ESP32-c6 모델을 이용하여 CSI데이터를 수집하고 이를 활용하여 실내 환경에서의 사람 수 추정(Human Counting), 구역 위치 인식(Localization), 개인 식별(Identification)을 동시에 출력하는 실제 현실성 있는 환경에서의 타겟팅이 목표인 Wi-Fi 센싱 시스템을 구현하는 것을 목표로 한다. 이 시스템은 보편적으로 보급된 Wi-Fi 장비나 인프라를 그대로 활용할 수 있고, 카메라 기반 시스템의 개인정보 침해 문제도 예방할 수 있다. 또한 기존의 단일 기능 중심 연구의 한계를 보완하고 다수의 센싱 정보를 사용자가 효과적으로 실시간 모니터링을 하는 것이 가능해질 것이다.

2. 연구 배경

2.1. 무선통신과 Wi-Fi

2.1.1. 무선통신과 주파수 대역

무선통신은 둘 또는 그 이상의 지점 사이에서 케이블과 같은 물리적인 전기 전도체의 연결 없이 정보를 전송하는 것을 의미한다. 주로 전자기파, 적외선, 초음파 등을 활용하게 된다. 유선통신과 비교하면 공간적 제약이 적고 이동성이 보장된다는 큰 장점이 있으나, 주변 환경의 구조물이나 다른 전파에 의해 간섭(Interference)을 받기 쉽다는 특징이 있다.

각 무선기기는 자신의 무선 신호를 혼선없이 찾아내도록 다른 신호와 겹치지 않는 주파수 영역인 대역폭(Bandwidth)을 가진다. 이 주파수 특성은 통신의 속도와 도달 거리를 결정 하는 요소다. 일반적으로 주파수 대역이 높아질수록 더 많은 데이터를 고속으로 전송할 수 있지만, 파장이 짧아져 전파의 도달 거리가 줄어들고 인체나 벽 같은 장애물에 의한 감쇠 및 반사 영향이 커지게 된다. 센싱 기술은 이러한 환경의 영향을 받는 전파의 특성을 이용한다.

2.1.2. Wi-Fi 통신 구조

본 연구에서 실내 센싱의 매개체로 사용하는 Wi-Fi는 IEEE 802.11 표준을 기반으로 하는 대표적인 무선망 프로토콜이다. Wi-Fi 네트워크는 크게 인터넷 망과 연결되어 신호를 중계하는 AP(Access Point, 무선 공유기)와, 이 신호를 수신하여 통신을 수행하는 STA(Station, 스마트폰 및 단말기)로 구성된다. 주로 2.4GHz, 5GHz 대역을 사용하며, AP와 STA간에 무선 패킷을 주고 받는다.

관련된 기술은 OFDM(Orthogonal Frequency Division Multiplexing)이 있다. 이는 특정 주파수 대역을 여러 서브캐리어로 쪼갬 후, 각 서브 캐리어에 데이터를 담아 동시에 전송하는 디지털 변조 방식이다. OFDM을 통해 주파수 대역의 효율성이 증가한다.

또한 MIMO(Multiple Input Multiple Output)는 송신과 수신을 위한 안테나를 여러개 사용하는 기술로, 동시에 여러 데이터를 보내거나 같은 데이터를 여러 경로로 전송하는데 사용된다.

2.1.3. 다중경로 전파

Wi-Fi 신호가 실내공간을 이동할때 신호는 송신기에서 수신기로 곧게 이어지는 경로로만 전달되지 않는다. 직선으로 전송되던 Wi-Fi 전자기파가 각종 구조물에 의해 반사, 굴절, 회절되는 다중경로 전파(multiple propagation)이 발생하게 된다. 이로 인해 동일한 신호가 서로 다른 경로를 거쳐 시간차를 두고 수신기에 도달하게 된다. 센싱의 관점에서 이러한 특성을 활용하여 신호에 반영된 환경 변화 정보를 통해 사람이 특정 구역에 존재하는지, 누구인지 알아내도록 한다.





Fig. 2-x : WiFi signal propagation, A Survey on Human Behavior Recognition Using Channel State Information

2.2. CSI

CSI(Channel State Information)란, Wi-Fi 신호가 사람이나 물체에 의해 반사/굴절되면서 변화한 채널 정보를 의미한다. Wi-Fi 신호는 여러가지 경로로 전파되어 주변 물체나 사람의 움직임에 의해 신호의 세기와 도달시간이 변화한다. 이러한 특성을 활용한 CSI 데이터 분석을 통해 공간 정보를 추론할 수 있다.

송신기에서 수신기로 전파되는 무선 신호의 특성은 i , q 값의 복소수(Complex number) 형태로 표현된다. i , q 값을 통해 신호의 세기(진폭)와 도달시간(위상)을 알 수 있다.

그림에서 진폭과 위상은 각각 길이와 각도를 계산하여 구한다.



$$A = \sqrt{I^2 + Q^2}$$

$$\theta = \arctan\left(\frac{Q}{I}\right)$$

Fig. 2-[x](#) : CSI amplitude(진폭)와 phase(위상) 계산식

2.3. ESP32-c6

2.3.1. 특징

스펙



항목	내용
MCU	ESP32
WiFi	IEEE 802.11 b/g/n
Frequency	2.4GHz
cost	6~8\$
Power	3.0V~3.6V

Fig. 2-[x](#) : ESP32-c6 스펙 설명

CSI 데이터 측정에 사용한 장비인 ESP32-c6은 저렴하면서 저전력으로, IOT 분야에서 많이 사용되는 장비이다. Wi-Fi IEEE 802.11 b/g/n 프로토콜을 따르며, 주파수는 2.4GHz이다. 특히 공식 개발 환경인 ESP-IDF에서 CSI 수신 콜백 API를 네이티브로 제공하여, 비교적 쉽게 CSI 데이터를 추출해낼수 있다.

2.3.2. 패킷 전송 방식

Generation	IEEE Standard	Max Link Rate (Mbits/s)	Radio Frequency (GHz)	Modulation	Adopted
Wi-Fi 0*	802.11	1-2	2.4	FHSS	1997
Wi-Fi 1*	802.11b	1.11	2.4	QPSK	1999
Wi-Fi 2*	802.11a	6-54	5	16 QAM	1999
Wi-Fi 3*	802.11g	6-54	2.4	64 QAM	2003
Wi-Fi 4	802.11n	72-600	2.4/5	64 QAM	2008
Wi-Fi 5	802.11ac	433-6933	5	256 QAM	2014
Wi-Fi 6	802.11ax	572-9608	2.4/5	1024 QAM	2019
Wi-Fi 6e	802.11ax	574-9608	2.4/5/6	1024 QAM	2020
Wi-Fi 7	802.11be	1376-46120	2.4/5/6	4096 QAM	(2024)

Fig. 2-[x](#) : Wi-Fi 버전별 IEEE표준과 특성

본 연구에서 사용한 공유기는 Wi-Fi 4 방식으로 통신하여 802.11n 표준을 따른다.

FIGURE 2.1 Data-Link and Physical layers




Fig. 2-[x](#) : Data-Link and Physical layers,

<https://mrncciew.com/2014/10/14/cwap-802-11-phy-ppdu/> Page 39 – CWAP Official Study Guide (Certified Wireless Analysis Professional)

Wi-Fi의 물리 계층(Physical layer)에서 전송되는 패킷의 단위를 PPDU(PLCP Protocol Data Unit) 라고 한다. MAC 계층에서 전달받은 실제 데이터(MPDU)에 물리 계층 전용 프리앰블(Preamble)과 헤더(Header)를 덧붙여 만들어 진다. 이것은 수신기에서 패킷이 날아오고 있음을 감지하고(Detection), 신호의 타이밍을 맞추고(Synchronization), 주파수 오프셋을 보정하며, CSI 데이터를 추정할 수 있도록 한다.




Fig. 2-x : 802.11n HT Packet Format




Fig. 2-x : PPDU format, IEEE P802.11n™/D11.0 p.262 fig.20-1

802.11n은 802.11a/g 방식 기기와의 호환성을 위해 Mixed format PPDU를 사용한다. 802.11n 패킷의 PPDU 프리앰블에는 송수신기가 사전에 미리 알고 있는 훈련 신호(Training Field)가 포함되어 있으며, 이를 통해 CSI 데이터를 추정한다. 프리앰블은 HT와 L-LTF 부분으로 나뉘어진다.

L-LTF (Legacy Long Training Field)는 PPDU 프리앰블의 앞부분에 위치한다. 이것은 802.11 a/g를 이용하는 구형기기에서 신호를 인식하고 채널을 추정하기 위한 레거시용 훈련 신호이다.

HT(High Throughout) 방식은 802.11n 표준을 부르는 명칭으로, MIMO와 40MHz 대역폭을 사용하여 전송속도를 크게 높인 방식이다.

HT-LTF (High Throughput Long Training Field): L-LTF 뒤에 이어지는 802.11n 전용 훈련 신호이다. 송수신기간의 MIMO 안테나 경로 각각에 대한 미세한 채널 상태를 추정하기 위해 사용된다.

2.3.3. CSI 데이터 추정 방식

20.3.9.3.4 Non-HT Long Training field

The non-HT long training OFDM symbol is identical to the Clause 17 long training OFDM symbol. In the 20 MHz channel width, the long training OFDM symbol is given by:

$$L_{-26,26} = \{1, 1, -1, -1, 1, 1, -1, 1, -1, 1, 1, 1, 1, 1, -1, -1, 1, 1, -1, 1, 1, 1, 0, 1, -1, -1, 1, 1, -1, 1, -1, 1, -1, -1, -1, -1, -1, 1, 1, -1, -1, 1, -1, 1, 1, 1, 1\} \quad (20-11)$$

Fig. 2-[x](#) : OFDM symbol, IEEE P802.11n™/D11.0 p.277 fig.20-11




Fig. 2-[x](#) : PPDU format과 OFDM symbol

본 졸업과제에서 사용한 수신기에서는 L-LTF에 담긴 OFDM symbol을 통해 CSI 데이터를 계산한다. 이것은 미리 약속된 신호로, 길이 52의 수열을 OFDM으로 보내게 된다. 64개의 서브캐리어에서 하나당 312.5kHz를 사용하여 총 20MHz를 이용한다. 데이터를 이용할 때 파일럿 서브캐리어에 해당하는 11, 25, 32, 39, 53번 (그림에서 -21, -7, 0, 7, 21번에 해당) 서브캐리어는 사용하지 않는다. 실제로 데이터를 측정했을 때 값이 0으로 나타나는 0, 1, 2, 3, 61, 62, 63번 서브캐리어도 제외한다.




Fig. 2-[x](#) : 20MHz OFDM




Fig. 2-[x](#) : OFDM symbol 전송 과정

송신기에서 수열을 전송할때 BPSK 변조에 따라 i 값(실수부)을 -1과 1로 나타내고 빈 서브캐리어를 0으로 표시한다. 초기의 q 값(허수부)은 0이 된다. 이것이 반사, 회절, 산란으로 인해 진폭과 위상이 변하게 되면 수신기에서 신호를 받았을때 변화된 값을 얻게 된다. 이렇게 변화한 i, q 값을 통해 공간정보를 분석한다. **Espressif**에서는 변화한 i, q 값을 8비트 정수로 스케일링하여 출력하므로 -128~127 범위로 스케일링된 데이터를 사용한다.

2.4. 전처리

2.4.1. Window Sliding




Fig. 2-[x](#) : stride 2에서 윈도우 슬라이딩 수행 예시

시간에 따라 패킷을 측정하였을때, 하나의 패킷에서 추출한 CSI 데이터는 환경이나 하드웨어의 영향으로 순간적인 노이즈를 포함할 가능성이 존재한다. 왜곡을 줄이고 시간의 흐름에서 신호의 특성을 대표하기 위해 여러 패킷을 묶어 하나의 시계열 윈도우(Window) 단위로 구성하였다. 또한 윈도우를 특정 간격(stride)에 따라 윈도우를 이동시키며 데이터를 묶는 윈도우 슬라이딩(Window Sliding)을 적용하였다. 이를 통해 노이즈를 줄일수 있고, 중첩되는 구간을 통해 단일 윈도우보다 더 많은 학습 데이터를 확보할수 있다. 입력 데이터의 전처리 과정에 활용한다면 KNN 분류기와 같은 모델의 식별 정확도와 안정성을 높일수 있다.

2.5. 시각화 / 평가

2.5.1. Confusion Matrix / Heatmap




Fig. 2-[x](#) : 히트맵 예시

모델이 주어진 테스트 데이터를 얼마나 정확하게 맞추는지 평가하기 위한 혼동행렬(Confusion Matrix)를 히트맵(Heatmap) 형태로 시각화하였다. Y축은 실제 정답

라벨(True), x축은 모델의 예측결과(Predicted)로 표시한다. 모델의 예측 정확도가 높을수록 정답라벨과 예측결과가 일치하는 교차점에 데이터가 집중된다. 그림과 같이 좌측 상단에서 우측 하단을 따라 짙은 색이 형성될수록 정확도가 높다고 볼수 있다.

2.5.2. 그래프




Fig. 2-x : CSI 진폭 그래프 예시

CSI 신호를 분석한 뒤 시각화는 여러 신호의 전반적인 형태와 패턴 일치도를 직관적으로 비교할 수 있도록 서브캐리어별 진폭의 크기를 나타내는 선 그래프를 사용하였다. X축은 서브캐리어 인덱스, y축은 진폭의 크기를 나타낸다.

2.5.3. RMSE

$$RMSE = \sqrt{\sum_{i=1}^n \frac{(\hat{y}_i - y_i)^2}{n}}$$

Fig. 2-x : RMSE 계산식

두 CSI 데이터 신호의 유사성을 정량적으로 평가하기 위해 RMSE(Root Mean Square Error)를 활용하였다. 이는 전체 서브캐리어별 진폭의 차이를 구한 후 제곱하여 합산한 후 제곱근을 씌우는 연산으로, 원본 진폭 데이터와 동일한 척도(scale)로 두 신호의 오차를 직관적으로 파악할 수 있다. 두 신호의 형태가 불일치 할수록 오차가 커져 RMSE는 높은 값을 갖게 되고, 0에 가까울수록 유사함을 나타낸다.

2.6. PCA




Fig. 2-~~x~~ : 첫번째 주성분 예시

PCA(주성분 분석)은 고차원의 데이터를 주성분에 따라 저차원의 데이터로 압축하는 비지도 학습이다. 주성분(Principal Component)이란 데이터의 흠어짐(분산)이 가장 큰 방향을 의미하고, 이러한 주성분의 축에 데이터를 투영(Projection) 하여 정보가 압축된 부분공간(Subspace)을 얻을 수 있다.



Fig. 2-~~x~~ : 2차원에서의 군집 형성 예시

CSI 데이터에 PCA를 적용하면 사람을 구분하는 특징이 잘 나타나는 분산이 큰 정보는 상위 주성분에 압축되고, 분산이 작은 하드웨어 및 환경 노이즈는 하위 주성분으로 분리된다. 이때 상위 주성분만을 선택하여 노이즈를 제거하고, 축소된 공간에 데이터를 표시하여 군집을 형성하는지 확인할 수 있다. 뚜렷한 군집을 이루는 데이터를 분류 모델에 적용한다면 모델의 성능을 크게 향상시킬 수 있다.

분산 보존율은 추출된 주성분이 차원 축소 전 데이터의 흠어짐(분산)을 얼마나 잘 유지하는지 나타내는 값이다. 이 비율이 높을수록 데이터가 축소되어도 원본의 구조와 정보량을 손실 없이 잘 보존하고 있음을 의미한다.

2.7. KNN Classification




Fig. 2-x : KNN 클래스 결정

KNN(K-Nearest Neighbors) 알고리즘은 새로운 데이터가 입력되면 기존 학습 데이터와의 공간적 거리를 계산한 후, 가장 가까운 **K**개의 이웃을 선택하여 클래스를 결정한다. 본 연구에서는 CSI 데이터로부터 추출된 특징 벡터(**feature vector**)가 기존 학습 데이터 중 어떤 사람의 **feature**와 가장 가까운지 비교하여 사람을 식별하도록 하였다.

CSI 데이터의 패턴은 체형이나 호흡수와 같은 사람의 고유한 특징에 따라 다르게 나타나 서로 다른 **feature**의 분포를 형성한다. KNN은 이러한 **feature**간의 유사성을 복잡한 모델 학습 없이도 거리 기반으로 쉽게 비교할 수 있어 딥러닝 모델 학습 이전에 사용자 식별의 가능성을 검증하는데 효과적이다.

2.8. CNN




Figure 4.1: Convolutional Neural Networks architecture

Fig. 2-x : Convolutional Neural Networks architecture,

Convolutional Neural Networks (CNN) for Detecting Fruit Information Using Machine Learning Techniques(2020)

CNN(Convolutional Neural Network)은 데이터의 국소적 패턴으로부터 특징을 추출하는데 특화된 딥러닝 모델이다. 이미지 분석에서 CNN을 활용한다면 서로 가까운 픽셀간 상관관계를 통해 선, 모서리와 같은 특징을 찾는다. 이미지 분석과 같이 CSI 데이터는 유효 서브캐리어가 주파수 순서대로 존재하는것에 기반하여 주변 서브캐리어가 나타내는 값에 대한 특징을 찾는데 모델을 사용하였다. 입력 데이터의 형태가 1차원 배열일 경우 1D CNN, 2차원 행렬일 경우 2D CNN을 채택하였다.

CNN의 특징추출 과정은 합성곱(Convolution)과 풀링(Pooling) 계층의 반복으로 이루어진다.

Convolution에서는 필터가 입력 데이터를 슬라이딩 윈도우 방식으로 이동하며 인접한 값들 간의 가중치를 계산한다. 이를 통해 주변 요소간의 변화 패턴이나 특징을 포착한다.

Pooling에서는 합성곱을 거친 결과인 특성 맵(feature map)의 크기를 줄여 주요한 특징만 압축하는 과정이다. 이를 통해 모델이 미세한 노이즈나 오차에 대해 강건성(Robustness)를 갖추도록 한다.

이러한 Convolution과 Pooling의 반복에 따라 초기에는 서브캐리어간 미세한 진폭 변화와 같은 low-level의 특징을 추출하고, 깊은 층으로 갈수록 여러 서브캐리어간 거시적인 패턴을 학습하게 된다.

본 연구에서는 단일 신호 분석을 위한 일반 CNN에 더하여 두 신호간 상호 특징을 비교하고 분석하기 위해 Dual CNN, Siamese Network, U-Net 등 다양한 확장형 신경망 구조를 활용하였다.

3. 연구 내용

3.1. 시나리오1: 단일 송수신기 환경에서 CSI 분석

본 졸업과제의 연구 내용은 크게 시나리오1과 시나리오2로 구분된다. 시나리오1에서는 단일 송수신기, 시나리오2에서는 4쌍의 다중 송수신기 환경에서 실험을 수행했다. 시나리오1에서는 WiFi CSI 데이터를 기반으로 사람 및 위치 식별 가능성, CSI 데이터 합성 및 분리 가능성, 데이터 분석 모델의 날짜별 강건성을 확인했다.

3.1.1. 시나리오1-1: 사람 & 위치 식별 가능성 확인

3.1.1.1. 시나리오1-1 실험 목적

시나리오1-1은 첫 번째로 진행한 실험이다. 실내 신호 식별 시스템을 만들기 전에 우선 WiFi CSI 데이터로 사람 및 위치를 식별할 수 있는지 가능성을 알아봐야했다. 따라서 가장 간단한 환경을 구성하고 사람 및 위치 식별 가능성을 확인했다. 사람과 위치에 따라 데이터가 가지는 특성이 서로 구별되는지 알아보기 위해 PCA 분석을 활용하여 차원을 축소하였을때 특성에 따른 군집이 어떻게 형성되는지 알아보았다.

3.1.1.2. 시나리오1-1 실험 환경



Fig. 3-1 : 시나리오1 실험 장소(자연대연구실험동 313-1호)

실험은 자연대연구실험동 313-1호에서 진행했다. 단순한 직사각형 구조로 가구가 없는 공실을 택하여 WiFi 전파가 최대한 다른 영향을 받지 않도록 구성했다.




Fig. 3-2 : 시나리오1 실험 구조

실험 환경은 위 그림(Fig. 3-2)과 같이 송수신기 Tx-Rx 한쌍과 좌측, 중앙, 우측 3개의 위치로 나눠 구성했다. 중앙 위치는 Tx-Rx 직선 상에 존재하여 LoS(Line of Sight)에 해당한다. 중앙에 사람이 위치하면 비교적 강한 신호들을 가로 막아 식별 정확도가 낮아질 것으로 예상했다. 각 위치에 적힌 숫자는 실험 순서를 가리키며 중앙, 우측, 좌측순으로 데이터를 수집했음을 의미한다.

3.1.1.3. 시나리오1-1 실험 데이터

데이터 수집은 하루에 19개의 case를 수집하여 총 5일간 진행했다. 실험에 참가한 인원은 총 4명으로 조교, 민현, 민경, 한별이다. 한 개의 case 당 1분씩 측정했으며 esp-32는 초당 10개의 패킷을 수집하므로 한 개의 case 당 대략 600개의 CSI 데이터가 수집된다. case1은 아무도 방에 존재하지 않을 때의 CSI 데이터를 수집한 케이스다. case2~13은 한 명씩 중앙, 우측, 좌측을 번갈아가며 1분씩 수집한 케이스다. Case14~19는 한 명은 좌측, 나머지 한 명은 우측에 서서 1분씩 수집했다.

Case	Person
1	Empty room
2, 3, 4	민경(Center, Right, Left)
5, 6, 7	한별(Center, Right, Left)
8, 9, 10	민현(Center, Right, Left)
11, 12, 13	조교(Center, Right, Left)
14	민경 + 조교
15	한별 + 조교
16	민현 + 조교
17	조교 + 민경
18	조교 + 한별
19	조교 + 민현

Fig. 3-3 : 시나리오1 데이터 시나리오

기존의 WiFi CSI 연구들은 데이터 수집 과정에서 가만히 서서 데이터를 수집하지 않고 정해진 경로를 따라 일정하게 움직이는 상태에서 데이터를 수집했다. 일정한 움직임을 기록한 CSI 데이터를 딥러닝 모델에 학습시키면 사람 고유의 걸음 걸이를 학습해 식별하기 쉬워진다는 장점이 있다. 하지만 본 졸업과제에서 구현하고자 하는 실내 신원 식별 시스템은 사용자의 상태가 대체로 움직이지 않는 정적 상태인 것을 특징으로 하기 때문에 정적인 상태에서의 사용자의 고유 특징들을 찾아내는 것을 목표로 했다.

3.1.1.4. 시나리오1-1 데이터 전처리 및 사용 모델

수신기로부터 수집된 CSI 데이터는 다음과 같이 엑셀 데이터로 저장된다.

rx_id	tsf_raw	i0	i1	...	i63	q1	q2	...	q63
1	847...	0	0	...	0	0	0	...	0
1	847...	0	0	...	0	0	0	...	0
1	847...	0	0	...	0	0	0	...	0
...									
1	847...	0	0	...	0	0	0	...	0

1 packet

Fig. 3-4 : CSI Raw Data

수집된 CSI Raw Data는 null carrier를 포함한다. 64개의 서브캐리어 중 파일럿 신호, 가드 밴드, DC 노이즈 서브캐리어에 해당하는 12개를 제거하므로 총 52개의 서브캐리어만 사용했다.

null carrier = [0, 1, 2, 3, 11, 25, 32, 39, 53, 61, 62, 63]

i0	i1	i2	i3	q0	q1	q2	q3
0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0

Fig. 3-5 : null carriers

Null carrier를 제거한 뒤에 i, q 복소수 값으로 진폭을 계산한다. 진폭 계산식은 단순 유클리디언 거리 계산과 동일하다.

$$A = \sqrt{I^2 + Q^2}$$

Fig. 3-6 : 진폭 계산식

각 서브캐리어별로 진폭을 계산하므로 패킷 당 52개의 진폭값이 계산된다. 이해를 돕기 위해 진폭 그래프를 시각화하여 아래 그림(Fig. 3-8)을 첨부했다. Fig. 3-8은 한 사람의 좌측, 중앙, 우측 CSI 데이터의 각각 600개(총 1800개)의 패킷을 서브캐리어별로 평균내서 1개의 대표 진폭값을 표시한 그래프다.





Fig. 3-7 : CSI 진폭 그래프 시각화


3.1.1.5. 시나리오1-1 사람 식별 가능성 확인 결과



case1~13	day1	day2	day3	day4	day5
분산 보존율	55.6%	56.2%	52.4%	43.6%	41.4%

먼저 1인 데이터를 나타내는 **case1~13**의 PCA분석 결과이다.

1인 데이터는 동일한 조건의 데이터끼리 밀집하는 경향을 보여주어 사람과 위치에 따른 고유한 특징이 구별될것으로 생각하였다.



case14~19	day1	day2	day3	day4	day5
분산 보존율	57.2%	66.1%	38.4%	56.8%	39.8%

2인을 측정 한 데이터인 **case14~19**의 PCA분석 결과이다.

2인 데이터는 1인 데이터에 비해 겹침이 많아 사람이 달라져도 비슷한 특징을 가져 분리가 잘 이루어지지 않을것으로 예상되었다.

3.1.2. 시나리오1-2: 사람 & 위치 식별 시도

3.1.2.1. 시나리오1-2 실험 목적

시나리오1-1을 통해 데이터별로 특징이 구분됨을 확인하였기 때문에 CSI 데이터를 모델에 적용한다면 사람과 위치의 식별이 잘 이루어질것으로 기대하였다.

3.1.2.2. 시나리오1-2 데이터 전처리 및 사용 모델

KNN을 통해 CSI 데이터를 분석하기 위한 전처리와 학습 과정은 다음과 같다.




Fig. 3-8 : 데이터 전처리 과정

시나리오1-1의 전처리에서 윈도우 슬라이딩 기법을 추가로 수행하였다. 학습을 진행할 때는 600개의 패킷을 서브캐리어별로 전체 평균을 구하지 않고 크기 10의 윈도우/스트라이드 기법을 사용해서 학습을 진행한다. 윈도우 기법을 사용한 이유는 노이즈와 이상치의 영향을 줄이기 위함이다. 이후 KNN모델을 적용한다.

3.1.2.3. 시나리오1-2 사람 & 위치 식별 시도 결과




Fig. 3-9 : 시나리오1-2 사람 식별(Human Identification) 결과 히트맵

Day	Accuracy
1	96.56%
2	95.22%
3	97.64%
4	95.61%
5	91.92%

Human Identification

**Average Accuracy
95.39%**

Fig. 3-10 : 시나리오1-2 사람 식별 정확도

시나리오1-2에서 사람 식별의 경우 정확도는 95.39%로 나왔다.




Fig. 3-11 : 시나리오1-2 위치 식별 결과 히트맵

Day	Accuracy
1	100%
2	100%
3	99.32%
4	99.66%
5	99.66%

Position Identification

Average Accuracy
99.73%

Fig. 3-12 : 시나리오1-2 위치 식별 정확도

(위치별 식별 성능 차이 그림 삽입)

시나리오1-2에서 위치 식별의 경우 99.73%의 정확도가 산출됐다. 이로써 사람 식별, 위치 식별 둘 다 95%가 넘는 높은 정확도를 보이므로 WiFi CSI 데이터로 사람 및 위치를 식별할 수 있다는 결론을 내렸다. 또한 위치를 식별하는 것보다 사람을 식별하는 것이 더 어려운 과제임을 파악했다. 그리고 위치별로는 뚜렷한 식별 성능 차이를 보이지 않았다.

3.1.3. 시나리오1-3: 1인 데이터 합성 시도

3.1.3.1. 시나리오1-3 실험 목적


시나리오1-1에서 사람, 위치 식별 가능성을 확인하고 시나리오1-2에서 KNN 모델을 통해 식별을 시도하였고 높은 정확도를 보였다. 하지만 치명적인 문제점이 남아있는데 현재 학습 모델로는 수집된 데이터 범위 내에서만 추론이 가능하다는 점이다. 수집된 학습 데이터는 인원이 1~2명인 경우만 수집되어있어 2인까지는 식별이 가능하다. 하지만 3인 이상을 식별해야할 경우 새로운 데이터를 수집해야하며 그 경우의 수는 기하급수적으로 늘어난다. 이 문제를 해결하기 위해 1인 데이터만 사용하여 2인 이상 데이터를 생성해내거나 혹은 역으로 2인 이상 데이터를 분리하여 1인 데이터의 조합을 알아내야한다. 시나리오1-2에서는 1인 데이터를 합성하여 2인 데이터를 생성해보았다.

3.1.3.2. 시나리오1-3 단순 덧셈 연산을 통한 1인 데이터 합성

파동은 선형적으로 중첩된다는 아이디어에서 출발하여 두 명의 CSI 데이터를 단순 덧셈 해보기로 했다. 예를 들어 case9(민현, 우측)와 case13(조교, 좌측)를 더하면 case19(조교 좌측, 민현 우측)와 유사할 것이라고 예상했다.

먼저 1인 데이터의 i, q값을 서로 더하여 합성 데이터를 만들어 진폭값을 구하였다.





case19의 데이터

실제 2인 데이터

i5	q5
10	17
-15	-15
-1	-21

사람 1이 왼쪽,
사람2가 오른쪽
i, q값

진폭 계산



원래 2인 데이터
진폭값

그리고 실제 2인 데이터의 i, q값으로 진폭값을 구하였고, 합성 데이터와 실제 2인 데이터를 그래프로 나타내어 비교하였다.




Fig. 3-13 : 시나리오 1-3 단순 덧셈 결과 진폭 그래프


단순 덧셈 결과, 기대와는 달리 서로 오차가 큰 모습을 보여줬다. 단순 덧셈만으로는 1인 데이터를 합성할 수 없었다.

3.1.3.3. 시나리오1-3 배경 차감을 통한 1인 데이터 합성

단순 덧셈 방법의 연장선상으로 배경 데이터(case1: empty room)를 차감하면 정확도를 개선시킬 수 있을 것이라 기대했다. 신호가 선형적인 결합이 가능하다고 가정했을 때, 실제 데이터를 (배경 + 사람1 + 사람2)의 조합으로 생각할 수 있고, 단순 덧셈의 경우 (배경 + 사람1) + (배경 + 사람2)의 조합이 될 것이다. 여기서 배경 데이터를 제거한다면 (사람1 + 사람2)의 정보만을 비교할 수 있을 것으로 생각하였다. 따라서 중복된 배경 데이터를 제거한 후 덧셈을 통해 합성한 뒤 실제 데이터와 유사한지 확인해보았다.

또한 정규화 과정도 포함시켜 CSI 데이터들의 스케일을 통일시켰다.

1인 데이터의 i, q값에서 배경 데이터의 i, q값을 뺄셈하였다. 이후 배경 데이터가 제거된 1인 데이터의 i, q값을 서로 더하여 진폭을 구하였다.






Fig. 3-0 :

실제 2인 데이터의 i, q값에서도 배경 데이터의 i, q값을 뺄셈하여 진폭값을 구한다.
앞에서 구한 배경 차감 합성 데이터와 실제 2인 데이터를 그래프로 비교하였다.




Fig. 3-14 : 시나리오1-3 배경 차감 결과 진폭 그래프

배경 차감 결과, Fig. 3-14를 보면 추론 결과와 정답인 원본 2인 데이터가 매우 유사한 형태를 보였다. 하지만 원본 2인 데이터 간에도 유사한 형태가 나타나기 때문에 (Fig.3-15) 추론된 2인 데이터가 정답 2인 데이터랑 매칭이 되는지 유효성을 검증해볼 필요가 있었다.




Fig. 3-15 : 시나리오1-3 2인 데이터 그래프
(모든 2인 데이터는 유사한 형태를 띈다)

[일자별 예측 일치도(Accuracy) 요약]	
• Scenario1_day1	: 2/6 시나리오 정확 매칭 (33.3%)
• Scenario1_day2	: 1/6 시나리오 정확 매칭 (16.7%)
• Scenario1_day3	: 2/6 시나리오 정확 매칭 (33.3%)
• Scenario1_day4	: 1/6 시나리오 정확 매칭 (16.7%)
• Scenario1_day5	: 1/6 시나리오 정확 매칭 (16.7%)
🏆 전체 일자 총합 정확도: 7/30 (23.33%)	

Fig. 3-16 : 배경 차감 방법 유효성 검증 결과

검증 방법은 1인 데이터로 배경 차감 방법을 통해 2인 데이터를 생성한 다음 case14부터 case19까지 비교하여 가장 오차가 적은 케이스가 정답 케이스인지 비교하는 방식으로 진행했다. 배경 차감 방법 유효성 검증 결과, 전체 평균 23.33%로 낮은 정확도를 보였다.

3.1.3.4. 시나리오1-3 1인 데이터 합성 시도 결과

시나리오1-3에서 1인 데이터만 수집하여 다수 인원 데이터를 생성하는 시도를 해보았다. 단순 덧셈 연산에 배경 차감 기법과 정규화 처리를 추가하여 진폭끼리 낮은 오차(RMSE)를 보였으나 애초에 2인 데이터끼리 매우 유사하다는 특징때문에 정답 케이스와 매칭이 잘 이루어지지 않는 결과를 보였다.

3.1.4. 시나리오1-4: 2인 데이터 분리 시도

3.1.4.1. 시나리오1-4 실험 목적

실내 신원 식별 시스템을 구현하기 위해서는 합성 혹은 분리 둘 중 하나를 완벽히 해내야 한다. 시나리오1-3에서는 합성 방법이 23.33%로 낮은 정확도를 보였으므로 실내 신원 식별 시스템에서 사용하기에 적합하지 않다고 판단했다. 시나리오 1-4에서는 분리를 시도해보기로 했다.

3.1.4.2. 시나리오1-4 2인 데이터 분리

시나리오1-4에서는 2인 데이터를 입력 데이터로, 1인 데이터를 정답 데이터로 사용했다. 학습 방법도 마찬가지로 KNN을 사용했으며 기타 요소들도 이전 시나리오들과 동일하다.

3.1.4.3. 시나리오1-4 2인 데이터 분리 시도 결과

Day	Accuracy
1	84.25%
2	96.67%
3	94.67%
4	91.39%
5	58.67%

Average Accuracy
85.13%

Fig. 3-17 : 시나리오1-4 2인 데이터 분리 시도 결과

시나리오1-4에서 2인 데이터 분리를 시도해본 결과 평균 85.13%의 정확도를 보였다. 특히 Day5에서는 58.67%로 매우 낮은 정확도를 보였다. 시나리오1-1의 PCA 분석에서 낮은 분산보존율을 보이며 데이터간 군집 형성이 잘 되지 않았던것을 고려하면 데이터의 특징이 유사하여 분리가 잘 이루어지지 않은 것이 원인이라고 볼수 있다. Day5를 제외한다면 91.745%로 6% 가량 정확도가 상승한다. 시나리오1-3을 통해 수집된 범위 내에서는 KNN 학습만으로 2인 데이터 분리가 가능함을 확인했다.

3.1.5. 시나리오1-5: 비동일 날짜 CSI 데이터 학습 시도

3.1.5.1. 시나리오1-5 실험 목적

실내 신원 식별 시스템에서 사용하는 추론 모델은 시간이 지나도 유효해야 한다. WiFi CSI 데이터는 실내에 배치된 사람, 사물에 영향을 받을 뿐만 아니라 기온, 습도 등에도 영향을 받기 때문에 시간이 지나면 정확도가 떨어질 수 있다. 일주일 전에 학습 시킨 추론 모델이 오늘 수집한 CSI 데이터로도 정확히 추론할 수 있어야 한다. 시나리오1-5에서는 서로 다른 날짜의 CSI 데이터들을 학습, 테스트하여 그 정확도를 확인해보았다.

3.1.5.2. 시나리오1-5 비동일 날짜 CSI 데이터 학습

시나리오1-5에서는 Day1~4를 학습 데이터로 사용하고 Day5를 테스트 데이터로 사용했다. 그 외의 데이터 전처리 및 사용 모델은 이전 시나리오와 동일하다.

3.1.5.3. 시나리오1-5 비동일 날짜 CSI 데이터 학습 시도 결과

Position	Average Accuracy
Center	53.94%
Right	41.16%
Left	39.06%

Fig. 3-18 : 시나리오1-5 비동일 날짜 CSI 데이터 학습 시도 결과

시나리오1-5에서 비동일 날짜 CSI 데이터를 학습해본 결과 평균 44.72%로 매우 낮은 성능을 보였다. 동일 날짜 데이터만 사용한 시나리오1-1의 사람 식별 정확도는 95.39%로 대략 50%의 차이를 보인다. 시나리오1-4를 통해 비동일 날짜 데이터를 사용하면 정확도가 대폭 감소함을 확인했다.

3.1.6. 시나리오1 결과

시나리오1-1에서는 PCA분석을 통해 데이터의 특성에 따른 분리 가능성을 알아보고, 시나리오1-2에서는 KNN으로 사람 및 위치 식별을 시도하여 각각 95.39%, 99.73%의 정확도로 WiFi CSI 데이터로 사람 및 위치 식별의 가능성을 확인했다. 시나리오1-3에서는 수집된 데이터 시나리오에서만 추론이 가능한 문제를 해결하기 위해 1인 데이터로 2인 데이터를 생성하는 시도를 해봤으나 최대 23.33%로 낮은 정확도를 보였다. 시나리오1-4에서는 수집된 데이터 시나리오 내에서 2인 데이터 분리를 시도했고 정확도 85.13%로 분리 가능성을 확인했다. 시나리오1-5에서는 시간이 흘러도 과거에 학습한 추론 모델이 미래에도 유효한지 강건성을 확인해보았으나 평균 44.72%로 낮은 정확도를 보였다.

결과를 종합하면 수집된 데이터 시나리오 내에서는 KNN 모델이 높은 정확도를 보이거나 수집되지 않은 데이터 시나리오에서는 매우 낮은 정확도를 보인다. 또한 시간이 지나면 학습시켜둔 모델이 쓸모가 없어지는 현상도 발견했다. 시간에 따른 모델 강건성 문제는 우선순위가 낮다고 판단했기 때문에 시나리오2에서는 수집된 데이터 시나리오 밖에서의 사람 및 위치 식별 문제를 우선적으로 해결하기로 했다.

3.2. 시나리오2: 다중 송수신기 환경에서 CSI 분석

데이터 수집 과정에서 모든 위치에 대한 모든 사람의 조합을 학습하기는 어려움이 있으므로 실제 시스템에서는 미리 학습시키지 않았던 사람의 조합도 고려해야 한다. 따라서 시나리오2에서는 실내 신원 식별 시스템 구현을 위해 수집되지 않은 조합의 데이터에 대한 식별 성능 문제를 해결해야 한다. 식별 성능 문제 난이도를 낮추기 위해 송수신기 쌍을 늘려 더 많은 공간 정보를 수집했고 데이터 수집 위치 간격도 넓혔다.

3.2.1. 시나리오2-1: 사람 & 위치 식별 시도

3.2.1.1. 시나리오2-1 실험 목적

실험 장소를 하나의 구역으로만 정의했던 시나리오1과 달리 시나리오2-1에서는 실험 장소를 중앙을 기준으로 분할하여 네 개의 구역으로 정의하였고, 송수신기의 위치와 간격도 다르게 구성했다. 시나리오2-1에서는 변경된 실험 환경에서도 시나리오1에서 사용한 학습 방법이 여전히 유효한지 확인하기 위해 시나리오1-1과 동일하게 사람 & 위치 식별을 시도해보았다. 나뉜 공간 각각에 수신기를 설치하여 구역별로 더 세부적인 정보를 수집할 수 있고, 사람간 간격이 멀어짐에 따라 신호가 더 뚜렷하게 구분되어 성능이 향상될 것으로 기대하였다.

3.2.1.2. 시나리오2-1 실험 환경

실험장소는 시나리오1과 마찬가지로 자연대연구실험동 313-1호에서 진행했다.



Fig. 3-19 : 시나리오2 실험 장소(자연대연구실험동 313-1호)

시나리오2 실험 구조는 아래 그림(Fig. 3-20)처럼 중앙에 송신기 하나, 각 모서리에 수신기 4개를 배치한 구조다.




Fig. 3-20 : 시나리오2 실험 구조

3.2.1.3. 시나리오2-1 실험 데이터

시나리오2-1에서는 한 사람 당 1분씩 섹션 1~4를 번갈아가며 데이터를 수집했다.

Case	Person
1	Empty room
2, 3, 4, 5	TA
6, 7, 8, 9	민경
10, 11, 12, 13	한별
14, 15, 16, 17	민현

Fig. 3-21 : 시나리오2 1인 데이터 시나리오

Case	Person
18, 19, 20	TA(섹션 1 고정), 민경(섹션 2, 3, 4)
21, 22, 23	TA(섹션 1 고정), 한별(섹션 2, 3, 4)
24, 25, 26	TA(섹션 1 고정), 민현(섹션 2, 3, 4)
	⋮
45, 46, 47	TA(섹션 4 고정), 민경(섹션 1, 2, 3)
48, 49, 50	TA(섹션 4 고정), 한별(섹션 1, 2, 3)
51, 52, 53	TA(섹션 4 고정), 민현(섹션 1, 2, 3)

Fig. 3-22 : 시나리오2 2인 데이터 시나리오

하루에 53개의 case를 수집했으며 case1은 빈 방, case2~17은 1인 데이터, case18~53은 데이터를 가리킨다. 하루에 53개의 case를 수집하여 총 4일간 212개의 case를 수집했다.

3.2.1.4. 시나리오2-1 사람 & 위치 식별 시도 결과

시나리오2-1에서 시나리오1-1과 동일한 방법으로 사람 & 위치 식별을 시도했다.

상태 (시나리오)	위치 [s1]	위치 [s2]	위치 [s3]	위치 [s4]
공석 (Empty)	99.93%	100.00%	99.67%	99.67%
창홍 (Changhong)	98.55%	100.00%	94.57%	100.00%
민경 (Minkyong)	95.04%	98.35%	86.29%	95.45%
한별 (Hanbyul)	96.21%	98.25%	95.35%	91.09%
민현 (Minhyun)	93.89%	96.12%	100.00%	99.15%
전체 평균 정확도	98.90%	99.55%	98.24%	98.90%

Fig. 3-23 : 시나리오2-1 사람 식별 시도 결과

시나리오2-1에서 사람 식별을 시도한 결과, 전체 평균 98.89%로 시나리오1-1보다 4.6%의 정확도가 상승해 유의미한 개선을 보였다.

위치 (수신기)	개별 정확도 (Accuracy)
위치 s1 (RX1)	99.47%
위치 s2 (RX2)	99.77%
위치 s3 (RX3)	98.80%
위치 s4 (RX4)	98.95%
전체 평균 정확도	99.25%

Fig. 3-24 : 시나리오2-1 위치 식별 시도 결과

위치 식별을 시도한 결과 시나리오1-1보다 0.5% 소폭 하락했지만 99.25%로 여전히 높은 정확도를 보여주었다. 시나리오2-1을 통해 시나리오2에서도 시나리오1에서 사용한 학습 모델들이 여전히 유효한 것을 확인했다. 또한 송수신기 쌍을 늘려 더 많은 공간 정보를 수집함으로써 사람 및 위치 식별 성능을 개선 됐음을 확인했다.

3.2.2. 시나리오2-2: KNN을 사용한 2인 데이터 합성 & 분리 시도

3.2.2.1. 시나리오2-2 실험 목적

시나리오2에서는 시나리오1에서 해결하지 못한 수집된 데이터 시나리오 밖에서의 식별 문제를 해결해야 한다. 시나리오2-1에서 시나리오2에서도 KNN 알고리즘으로 사람 및 위치를 식별할 수 있음을 확인했다. 시나리오2-2에서는 시나리오1-2에서 시도했던 합성 & 분리를 개선시켜 수집된 데이터 시나리오 밖에서의 식별 정확도를 상승시키는 것을 목적으로 한다.

3.2.2.2. 시나리오2-2 배경 차감을 통한 1인 데이터 합성 시도

시나리오2-2에서는 시나리오1-2와 마찬가지로 배경 차감 기법을 사용해서 데이터 합성 & 분리를 시도했다. 시나리오2-2에서는 동일 시점에서 CSI 데이터가 4배라는 점에서 더 높은 정확도를 기대했다.

Experiment Day	Total Bundles	Correct Matches	Accuracy	Avg GT RMSE
Day 1	36	14	38.89%	0.22693
Day 2	36	17	47.22%	0.23949
Day 3	36	16	44.44%	0.22719
Day 4	36	15	41.67%	0.25264

Fig. 3-25 : 시나리오2-2 배경 차감 결과

시나리오2-2에서 배경 차감을 시도한 결과 2일차에서 47.22%로 가장 높은 정확도를 보였다. 36개의 케이스(case18~case53) 중 17개의 케이스가 맞춰 거의 절반이 정답을 맞췄다. case2와 case7은 case18과 매칭이 되는데 case2와 case7을 합쳐 추론한 데이터가 case18~case53 중 case18과 가장 오차가 적어야 정답으로 판정된다. 시나리오1의 2인 데이터 합성에서 23.33%의 정확도를 보여준것과 비교하였을때 47.22%는 유의미한 결과로 보인다. 하지만 실내 신원 식별 시스템에서 사용하기에는 정확도가 여전히 낮다.

3.2.2.3. 시나리오2-2 호흡수 분석을 통한 2인 데이터 합성 & 분리 시도

시나리오2-2에서 배경 차감 뿐만 아니라 호흡수 분석을 통한 2인 데이터 합성을 시도해보았다. 사람마다 분당 호흡수(BPM)는 다르기 때문에 호흡수를 각 개인의 고유 특징으로 볼 수 있다. 만약 2인 데이터에서 두 사람의 호흡수를 정확하게 추출할 수 있다면 이점을 활용하여 다수 데이터에서 각 개인을 추론할 수 있을 것이라 기대했다. CSI 데이터는 초당 10개의 데이터를 수집되어 시계열 특성을 가진다. 이를 FFT(Fast Fourier Transform)를 사용하면 시간 영역을 주파수 영역으로 변환할 수 있다. 사람의 호흡 주파수 대역 10~24BPM(0.167Hz~0.4Hz)에서 피크값을 사람의 호흡수로 간주할 수 있다.




Fig. 3-26 : 시나리오2-2 호흡 주파수 시각화

위 그림(Fig. 3-26)은 case16(민현, section2)을 FFT를 사용하여 주파수 영역으로 변환한 그래프로 case16에 존재하는 주파수들을 볼 수 있다. 사람의 호흡 주파수 대역 0.167Hz~0.4Hz로 범위를 제한하고 피크값을 추출한 결과 0.269Hz로 16.1BPM이라는 결과를 얻었다. 날짜별, 인물별로 호흡수 평균을 계산하여 아래 그림(Fig. 3-27)과 같은 결과를 얻었다.

[사람별 x Day별 평균 호흡수(BPM) 변화 추이]					
Day	Day 1	Day 2	Day 3	Day 4	Overall
Subject					
민경	14.50	16.41	12.16	15.60	
민현	14.79	18.16	14.58	14.28	
조교	17.80	11.65	11.28	14.87	
한별	11.94	16.85	12.45	14.36	

Fig. 3-x : 시나리오2-2 인물/날짜별 호흡수 결과

시나리오2-2 호흡수 추출 결과 여러 문제점을 발견했다. 특정 케이스 특정 인물의 호흡수가 비정상적으로 높고 정상적으로 보이는 호흡수도 과연 그 사람의 호흡수가 맞는지 판단할 수 없었다.(정보 및 근거 추가) 해당 호흡수 결과를 검증하려면 CSI 데이터를 수집할 때 의료기기를 사용하여 그 사람의 호흡수를 동시에 측정하고 기록해야 한다. 또한 분리 알고리즘을 새로 찾아내야한다는 문제도 존재한다. Fig. 3-26을 보면 1인 데이터임에도 불구하고 호흡 주파수 대역에서 최대 피크값 주변에 유사한 피크들이 다수 분포되어 분리 문제 또한 어려울 것이라 예상했다. 따라서 호흡수로 2인 데이터를 분리하는 방법은 사용하지 않기로 했다.(수정)

3.2.3. 시나리오2-3: 딥러닝을 활용한 2인 데이터 합성 & 분리 시도

3.2.3.1. 시나리오2-3 실험 목적

시나리오2-2까지 연구를 진행하면서 WiFi CSI 다중 경로 환경에서 특징을 찾아 인물 데이터를 합성/분리를 수행하는 것은 사실상 불가능에 가까운 과제임을 깨달았다. 수집된 데이터 시나리오 밖에서의 식별 문제를 해결하기 위해서는 전통적인 머신러닝 방법으로는 부족하다. 따라서 딥러닝을 사용하여 추론 모델이 현재 CSI 데이터 시나리오의 보이지 않는 특징까지 학습하여 수집된 데이터 시나리오 밖에서의 식별 성능 문제를 해결하고자 하였다.

3.2.3.2. 시나리오2-3 2D CNN 합성/분리

딥러닝에는 다양한 학습 모델이 존재한다. 딥러닝 응용 분야로는 크게 컴퓨터 비전, 시계열 및 자연어 처리, 생성 모델, 멀티 모달 및 본 졸업 과제에서는 WiFi CSI 데이터를 학습시키기 위해 2D CNN 모델을 사용하기로 했다. 2D CNN 모델을 사용하기로 결정한 이유는 CSI 데이터를 하나의 이미지로 간주할 수 있기 때문이다. 수신기는 초당 10개의 CSI 데이터를 수집하므로 분당 600개의 데이터를 수집한다. 이는 시간축 x 서브캐리어축의 2차원 데이터임을 알 수 있다. 따라서 CNN을 활용한다면 서브캐리어에서 찾아볼 수 있는 인물의 특징 뿐만 아니라 시간에 따른 인물의 패턴도 알아서 학습해서 합성 및 분리를 원활히 수행할 것이라 기대했다.

=====	
Day	Top-1 Acc

Day 1	30.00%
Day 2	30.00%
Day 3	30.00%
Day 4	10.00%

Fig. 3-27 : 2D CNN 합성 모델 정확도

CSI 데이터를 2차원 이미지로 간주하므로 case 당 4개(수신기 개수)의 입력 데이터가 생성된다. 입력 데이터로 1인 데이터를 사용할 때 같은 수신기 데이터끼리만 사용했다. 그리고 데이터 누수를 막기 위해 case18~case43까지만 학습용으로 사용하고 case44~case53은 테스트용으로 분리시켰다. 2D CNN로 학습한 합성 모델의 정확도는 최대 30%를 보였다.

Day	Total Cases	Correct Matches	Accuracy (%)
Day 1	10	0	0.00%
Day 2	10	0	0.00%
Day 3	10	0	0.00%
Day 4	10	1	10.00%

Fig. 3-28 : 2D CNN 분리 모델 정확도

마찬가지로 2D CNN으로 분리 모델을 학습시켰을 때는 최대 10%로 1~3일차는 10개 중 하나도 맞추질 못 했다. 분리 정확도가 합성 정확도 보다 유독 낮게 나온 이유는 분리 문제 자체의 난이도 때문이다. 분리는 입력 2인 데이터 하나로 1인 데이터 두 개를 동시에 맞춰야 한다. 반면 합성은 입력 1인 데이터 두 개로 2인 데이터 하나를 맞추면 되기 때문에 분리 문제는 합성 문제 보다 정확도가 떨어질 수 밖에 없다. 합성 모델과 분리 모델을 학습시켜본 결과 둘 다 낮은 정확도를 보이고 있어 개선이 필요하다.

3.2.3.3. 시나리오2-3 2D CNN Dual Network

실내 신원 식별 시스템에서 신원을 식별하려면 1인 데이터를 합성하거나 2인 데이터를 분리해야 한다. 둘 중 하나만이라도 가능하다면 식별 또한 가능하다. 이는 모델을 학습할 때 합성 오차 혹은 분리 오차가 적은 방향으로 학습시킬 수 있음을 의미한다. 두 모델을 철저히 분리 시키고 학습 및 추론을 독립적으로 진행하면 두 모델 개인 측면에서의 정확도가 높다는 장점이 있다. 그러나 현재 실내 신원 식별 시스템은 평가 시 합성과 분리 둘 다 사용할 수 있다. 둘 중 하나만 사용한다면 나머지 평가 방법을 전혀 활용하지 않게 된다. 따라서 학습 시 합성과 분리를 동시에 진행한다면 기존보다 높은 정확도를 가질 수 있을 것이라 기대했다. 2D CNN에서 합성 및 분리 학습을 동시에 진행하는 모델을 아래 그림 (Fig. 3-30) 처럼 구성했다.




Fig. 3-29 : 2D CNN Dual Network

학습을 진행할 때 1인 데이터 2개, 정답 2인 데이터 1개를 각각 합성 모델, 분리 모델에 입력 데이터로 넣는다. 이후 합성 모델은 2인 추론 데이터를 산출하고 분리 모델은 1인 추론 데이터 2개를 산출한다. 합성 모델에서 나온 2인 추론 데이터는 분리 모델에 넣었던 2인 데이터와 오차를 비교한다. 분리 모델에서 나온 1인 추론 데이터 2개는 합성 모델에 넣었던 1인 데이터들과 오차를 비교한다. 해당 오차의 합을 전체 모델의 **Loss**로 계산하여 합성 오차 및 분리 오차가 적은 방향으로 합성 및 분리 모델이 학습을 진행하게 된다. 합성 모델과 분리 모델의 레이어 속 노드들은 물리적으로 분리가 되어있지만 **Loss** 식에 두 요소가 포함되므로 역전파 단계에서 합성 오차와 분리 오차의 합이 적어지는 방향으로 학습이 진행된다. **Loss** 식은 아래 식(Fig. 3-31)과 같다.

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{synth}} + \mathcal{L}_{\text{sep}}$$

Fig. 3-30 : 2D CNN Dual Network Loss 식

2D CNN Dual Network로 학습 시 사용한 데이터 케이스 및 시나리오는 이전 2D CNN 절에서 사용한 것과 동일하다. 2D CNN Dual Network의 학습 후 정확도는 아래 표(Fig. 3-32)와 같다.

Day	Top-1 Acc	Top-3 Acc	Mean Rank	Avg True MSE
Day 1	30.00% (3/10)	60.00% (6/10)	3.10위	56.0904
Day 2	20.00% (2/10)	70.00% (7/10)	2.70위	47.5493
Day 3	30.00% (3/10)	50.00% (5/10)	3.50위	49.9030
Day 4	10.00% (1/10)	60.00% (6/10)	3.70위	48.3422

Fig. 3-31 : 2D CNN Dual Network 결과

2D CNN Dual Network 결과 Day1~4일차 각각 30%, 20%, 30%, 10%의 결과를 얻었다. 비록 높은 정확도를 얻지 못 했지만 상위 3등 내에 든 케이스가 50~70%대 임을 확인할 수 있었다. 이는 모델이 학습을 하고는 있지만 애초에 2인 데이터 케이스끼리 매우 유사하다는 특징 때문에 정답 케이스를 정확히 매칭시키지는 못 하고 있는 것으로 해석된다.

3.2.3.4. 시나리오2-3 2D CNN Dual Network + Cycle

2D CNN Dual Network의 정확도를 향상 시키기 위해 합성 및 분리 모델 간 피드백 요소(Cycle)를 추가했다. 기존의 2D CNN Dual Network는 Loss 계산 단계에서 합성 오차와 분리 오차의 합만 존재하므로 상호보완적인 관계가 존재는 하나 약하다. 서로 보완해주는 피드백 단계를 추가한다면 정확도가 향상될 것이라 기대했다.




Fig. 3-32 : 2D CNN Dual Network + Cycle

2D CNN Dual Network + Cycle에서는 학습 시 두 모델이 추론한 데이터를 상대방에게 다시 학습시키는 피드백 구조를 추가했다. 예를 들면, case2와 case7을 입력 데이터로

받은 합성 모델이 추론한 2인 데이터를 다시 분리 모델에 넣어 1인 데이터 2개를 추론한다. 이 추론된 1인 데이터 2개를 다시 case2와 case7과 비교를 하여 오차를 구해 Loss를 계산할 때 사용한다. 이 관계를 통해 합성/분리 모델이 잘못된 추론 결과를 내놓더라도 한 번 더 데이터를 분석할 수 있는 기회가 서로에게 생기게 된다. 2D CNN Dual Network + Cycle의 Loss 식은 아래(Fig. 3-34)와 같다.

$$\mathcal{L}_{total} = \mathcal{L}_{synth} + \mathcal{L}_{sep} + 0.5 \times \mathcal{L}_{synth_cycle} \times \mathcal{L}_{sep_cycle}$$

Fig. 3-33 : 2D CNN Dual Network + Cycle Loss 식

Synth_cycle은 분리 모델에서 나온 추론 데이터를 합성 모델에 넣었을 때 추론 데이터의 오차를 의미한다. 반대로 sep_cycle은 합성 모델에서 나온 추론 데이터를 분리 모델에 넣었을 때 추론 데이터의 오차를 의미한다. 서로에게 미치는 영향력을 키우기 위해 두 항을 곱셈항으로 구성했다. 다만 cycle 항이 전체적으로 압도적인 영향력을 갖게 될 것을 우려하여 0.5를 곱해주었다. 2D CNN Dual Network + Cycle의 결과는 아래 표(Fig. 3-35)와 같다.

Day	Top-1 Acc	Top-3 Acc	Mean Rank	Avg True MSE
Day 1	30.00% (3/10)	60.00% (6/10)	3.10위	79.0435
Day 2	30.00% (3/10)	60.00% (6/10)	3.30위	51.2838
Day 3	40.00% (4/10)	60.00% (6/10)	3.20위	50.6803
Day 4	30.00% (3/10)	70.00% (7/10)	3.00위	48.6574

Fig. 3-34 : 2D CNN Dual Network + Cycle 결과

그 결과 day1~4에서 정답 케이스가 매칭되는 정확도는 각각 30%, 30%, 40%, 30%를 보였다. 2D CNN Dual Network의 정답 케이스 매칭 평균 정확도는 22.50%, 2D CNN Dual Network + Cycle의 정답 케이스 매칭 평균 정확도는 32.5%로 10%가 향상되었다. 뿐만 아니라 추론 데이터가 상위 3위 내로 들 확률은 62.5%로 기존의 2D CNN Dual Network 보다 2.5% 가량 상승했다(Fig. 3-36).

모델 구조	Top-1 Acc 평균	Top-3 Acc 평균	평균 순위
1. 2D CNN Dual Network	22.50%	60.00%	3.25위
2. 2D CNN Dual Network + Cycle	32.50%	62.50%	3.15위

▶ 성능 변화: Top-1 +10.00%p 상승 | Top-3 +2.50%p 상승 | 순위 0.10위 개선

Fig. 3-35 : 2D CNN Dual Network와 2D CNN Dual Network + Cycle 비교

2D CNN Dual Network + Cycle에서 피드백 관계를 추가함으로써 전반적인 정확도가 소폭 향상됐음을 보였다.

3.2.3.5. 시나리오2-3 2D CNN Dual Network + Cycle + 4-Rx

시나리오2-3의 2D CNN Dual Network + Cycle에서는 수신기 4개가 제공하는 추가 공간 정보를 제대로 활용하지 못 하고 있다. 시나리오2에서 CSI 데이터 케이스는 case당 대략 2400개의 CSI 데이터가 저장되어 있는데 수신기를 4개 운용했으므로 수신기당 600개의 데이터가 수집됐다. 2D CNN Dual Network + Cycle에서는 입력 데이터를 처리할 때 4개의 수신기에 해당하는 CSI 데이터들을 하나의 이미지로 간주하여 case당 4개의 입력 데이터를 처리한다. 즉, 2D CNN Dual Network + Cycle에서는 서로 다른 수신기 데이터들을 하나의 모델에 입력 데이터로 사용했었다. 이는 하나의 모델이 서로 다른 수신기에서 수집한 CSI 데이터들의 특징을 종합적으로 파악해서 정확도를 높여야하므로 어려운 과제인 것으로 보인다. 따라서 3.2.4절에서는 3.2.3절의 아키텍처를 계승하여 수신기별로 2D CNN Dual Network + Cycle 형태로 구성한 다음, 수신기에 해당하는 모델의 Loss들을 합친 총합 Loss가 적어지는 방향으로 아키텍처가 학습되도록 구현해보았다.




Fig. 3-36 : 2D CNN Dual Network + Cycle + 4-Rx 모델

2D CNN Dual Network + Cycle + 4-Rx의 아키텍처는 위 그림(Fig. 3-37)과 같다. 수신기 4개가 주는 CSI 데이터들을 각 모델이 독립적으로 학습하되 전체 모델은 각 모델의 오차가 적어지는 방향으로 학습하도록 구성하였다.

$$\mathcal{L}_{\text{total}} = \sum_{r=1}^4 (\mathcal{L}_{\text{synth},r} + \mathcal{L}_{\text{sep},r} + 0.5 \times \mathcal{L}_{\text{synth_cycle},r} \times \mathcal{L}_{\text{sep_cycle},r})$$

Fig. 3-37 : 2D CNN Dual Network + Cycle + 4-Rx

수신기별로 분리된 아키텍처를 구성함으로써 학습 모델이 각자 수신기에서 획득한 공간 특징을 이전 모델보다 더 효과적으로 학습하도록 만들어 전체적인 정확도가 향상될 것으로 기대했다. 2D CNN Dual Network + Cycle + 4-Rx의 결과는 아래와 같다.

Day	Top-1 Acc	Top-3 Acc	Top-5 Acc	Mean Rank
Day 1	50.00%	80.00%	90.00%	2.20위
Day 2	20.00%	70.00%	90.00%	3.00위
Day 3	40.00%	50.00%	80.00%	3.60위
Day 4	30.00%	50.00%	80.00%	3.80위

Fig. 3-38 : 2D CNN Dual Network + Cycle + 4-Rx 정확도

Day1에서 50%의 정확도를 보였다. 평균 35%로 이전 2D CNN Dual Network + Cycle과 비교했을 때 2.5% 소폭 향상됐다.

모델 구조	Top-1 Acc 평균	Top-3 Acc 평균	평균 순위
1. 2D CNN Dual Network	22.50%	60.00%	3.25위
2. 2D CNN Dual Network + Cycle	32.50%	62.50%	3.15위
3. 2D CNN Dual Network + Cycle + 4-Rx	35.00%	62.50%	3.15위

Fig. 3-39 : 모델 아키텍처 비교

3.2.3.6. 시나리오2-3 1D CNN Dual Network + Cycle + 4-Rx

시나리오2에서는 데이터를 수집할 때 가만히 서서 1분 동안 측정했었다. 이는 사실 CSI 데이터가 시간에 따른 변화가 거의 없음을 의미한다. 사람은 가만히 서있기 때문에 데이터 케이스에는 그 사람의 움직임 같은 동적인 고유 특징이 포함되지 않는다. 대신 그 사람의 호흡수나 에어컨 날개의 움직임 같은 작은 특징들이 포함될 가능성이 있다. 3.2.2.3 절에서 고유 특징을 추출하기 위해 호흡수 분석을 했을 때 호흡수를 CSI 데이터의 고유 특징으로 사용하기에는 미미한 특징임을 확인했다. 또한 에어컨 날개의 움직임은 노이즈로 간주되어 모델이 학습하는 데 방해가 되는 요소이다. 따라서 2D CNN을 사용할 때 데이터에 시간축을 포함한다면 오히려 방해요소를 학습할 가능성이 있다. 3.2.3.6 절에서는 2차원이 아닌 1차원 CNN을 수행하도록 아키텍처를 변경한다. 1D CNN Dual Network + Cycle + 4-수신기 모델은 이전 절의 아키텍처를 그대로 계승하되 2차원이 아닌 1차원으로 데이터를 학습한다. 이때 필터의 크기는 1x3으로 설정했고 진행 방향은 서브캐리어 축으로 하여 서브캐리어의 형태를 학습시키도록 설정했다.

	Sub_4	Sub_5	Sub_6	Sub_7	Sub_8
Packet_0	26.419689	24.738634	30.083218	961510	34.438351
Packet_1	27.784887	25.612497	33.301651	29.000000	37.121422
Packet_2	31.304953	27.459061	30.805843	24.207438	42.011902
Packet_3	28.160255	27.000000	36.000000	36.345562	36.878178
Packet_4	28.160255	29.154760	34.885529	38.078865	34.785053

Fig. 3-40 : 1D CNN Dual Network + Cycle + 4-Rx 필터의 진행 방향

또한 2D CNN에서는 케이스 하나를 4개의 이미지로 보므로 데이터가 부족하여 과적합이 발생할 수 있다는 단점도 존재했다. 1D CNN에서는 하나의 패킷을 하나의 입력 데이터로 처리하기 때문에 케이스당 대략 2400개를 입력 데이터로 사용 가능하므로 데이터 부족으로 인한 과적합을 예방할 수 있다.

1D CNN Dual Network + Cycle + 4-Rx의 학습 결과는 아래 표(Fig. 3-42)와 같다.

Day	Top-1 Acc	Top-3 Acc	Top-5 Acc	Mean Rank
Day 1	30.00%	60.00%	80.00%	3.00위
Day 2	40.00%	90.00%	90.00%	2.40위
Day 3	30.00%	40.00%	70.00%	4.00위
Day 4	40.00%	50.00%	70.00%	3.60위

Fig. 3-41 : 1D CNN Dual Network + Cycle + 4-Rx 정확도 표

Fig.3-42를 보면 정답 케이스로 매칭될 정확도(Top-1 Acc)는 35%를 달성했다. 특히 Day2와 Day4에서 40%를 달성하였다. Day 2에서는 상위 3위 내에 드는 정확도는 90.00%, 평균 순위 2.40위로 단일 Day 최고 성능을 기록했다. 다만 Day 3, 4의 편차로 인해 전체 Top-3 및 평균 순위는 기존의 2D CNN Dual Network + Cycle + 4-Rx 아키텍처 대비 소폭 하락했다.

3.2.4. 시나리오2 결과

모델 구조	Top-1 Acc 평균	Top-3 Acc 평균	평균 순위
1. 2D CNN Dual Network	22.50%	60.00%	3.25위
2. 2D CNN Dual Network + Cycle	32.50%	62.50%	3.15위
3. 2D CNN Dual Network + Cycle + 4-Rx	35.00%	62.50%	3.15위
4. 1D CNN Dual Network + Cycle + 4-Rx	35.00%	60.00%	3.25위

Fig. 3-42 : 시나리오2 결과

실패 원인 : 조교님이 고정이기 때문에 2인 데이터 케이스는 서로 유사할 수 밖에 없음.
애초에 어려운 문제.

0~4 관련 지식(도메인 지식 부족, 데이터마이닝 ppt)

3.3. 유니티 실내 신원 식별 시스템 개발

3.3.1. 유니티 툴 선정 이유

본 졸업과제에서는 실내 신원 식별 시스템을 개발하기 위해 대표적인 게임 엔진 중 하나인 유니티(Unity)를 사용했다. 유니티는 유니티 테크놀로지스(Unity Technologies)에서 개발한 크로스 플랫폼 게임 및 인터랙티브 3D/2D 콘텐츠 제작 엔진으로 물리 엔진, 그래픽 렌더링 파이프라인, 오디오, 애니메이션 시스템 등을 내장하고 있어 복잡한 저수준 프로그래밍 없이도 직관적인 컴포넌트 기반 아키텍처를 통해 다양한 디지털 콘텐츠를 신속하게 구현할 수 있다.

유니티를 실내 신원 식별 시스템을 개발하는 데 사용할 툴로 선정한 이유는 첫 번째로 3D 공간을 쉽게 매핑할 수 있기 때문이다. 프로젝트 목표 상 실험실 환경을 1:1로 구현하고 실시간 렌더링을 필요로 하기 때문에 쉽고 직관적으로 객체들을 렌더링할 수 있는 게임 엔진을 사용해야 했다. 게임 엔진에는 대표적으로 언리얼 엔진과 유니티 엔진이 있는데 언리얼 엔진은 Lumen, Nanite 등 사실적 그래픽을 위한 무거운 시스템이 탑재되어 있어 백그라운드 리소스 소모가 크다. 반면 유니티는 모든 측면에서 언리얼 보다 경량화된 버전으로, 본 졸업과제의 실내 신원 식별 시스템이 목표로 하는 장기간 상시 모니터링 클라이언트를 구동하기에 훨씬 안정적이고 가볍다. 또한 사용자를 매혹시킬만큼 아름답고 사실적인 고사양 3D 그래픽은 필요하지 않고 실제 실험실을 1:1로 단순화한 탐류 공간에서 4개의 섹션과 인원을 직관적으로 표출하는 것이

목표이기 때문에 언리얼 엔진 보다는 유니티를 사용하는 것이 현재 개발하고자 하는 실내 신원 식별 시스템에 적합하다.

두 번째로, 유니티는 파이썬 기반 AI 추론 서버와 원활한 실시간 연동 및 비동기 데이터를 처리하기에 용이하기 때문이다. 실내 신원 식별 시스템은 초당 10개의 CSI 데이터를 외부 딥러닝 서버에서 처리한 뒤 웹 소켓을 통해 결과를 전달 받아 1초 이내에 화면에 모니터링을 해야하는 실시간성을 목표로 했다. 유니티는 C#의 탁월한 **async/await** 비동기 처리 체계와 다양한 고성능 네트워크 라이브러리를 지원하고 있다. 따라서 **JSON** 데이터를 수신 및 파싱하는 과정에서 메인 렌더링 스레드의 지연을 방지하여 끊임 없는 실시간 모니터링 환경을 구축하기에 적합하다고 판단했다. 실제로 본 과제에서는 **FastAPI** 기반 추론 서버와 유니티 클라이언트 간 **NativeWebSocket**(유니티 전용 오픈소스 경량 웹소켓) 및 C#의 **async/await** 비동기 파이프라인을 구축하였다. 서버에서 수신된 **JSON** 패킷을 C# DTO 객체로 즉각 역직렬화하여 4개 구역 내 인원을 스폰하고 실시간 위치 갱신 및 퇴실 객체를 회수 처리 로직을 지연 없이 수행하도록 구현하였다.

세 번째로, 유니티는 관리자 인터페이스를 구현하는 데에도 유리하기 때문이다. 본 졸업과제의 실내 신원 식별 시스템은 장기간 상시 모니터링 역할을 수행해야 함으로써 복잡한 관제 및 경보 기능을 직관적이고 완성도 높게 구현해야 한다. 유니티는 애초에 게임 개발을 위해 제작된 툴로 사용자가 **UI/UX**를 쉽게 개발할 수 있는 환경을 마련해놓았다. 실내 신원 식별 시스템은 실험실을 1:1로 매핑한 3D 가상 공간과 인원 렌더링 뿐만 아니라 구역별 상태 패널, 미등록 객체 침입 및 특별 관리 대상 이탈 경보, 사용자 정보 관리 등 다양한 관리자 인터페이스를 요구한다. 유니티에서는 3D 공간 객체와 2D UI를 컴포넌트 기반으로 구현할 수 있기 때문에 두 요소 간 인터랙티브한 대시보드를 유니티 하나로 손 쉽게 구현할 수 있어 관리자 인터페이스를 구현하는 데에도 적합하다고 판단했다.

마지막으로 유니티는 크로스 플랫폼 확장성이 뛰어나 데스크톱(Window, Linux) 환경에서의 관제뿐만 아니라 향후 현장 관리자나 간병인 등이 사용하는 태블릿(Android/iOS) 혹은 웹 등 다양한 플랫폼으로 손쉽게 빌드 및 배포할 수 있다. 따라서 한 번의 개발로 여러 기기에서 접근 가능한 실내 신원 식별 시스템을 손 쉽게 구현할 수 있다.

3.3.2. 시스템 아키텍처




Fig. 3-43 : 실내 신원 식별 시스템 아키텍처

실내 신원 식별 시스템의 시스템 아키텍처는 그림 3- 에서 볼 수 있다. 송신기는 패킷의 LTF(Long Training Field)에 미리 약속한 LTS(Long Training Sequence)를 담아 수신기로 전송한다. 수신기는 Multipath의 영향으로 변화된 LTS에서 CSI 데이터를 계산한 뒤 공유기로 UDP 전송을 수행한다. 이 부분은 espressif에서 이미 구현된 기능들이다. 이후 공유기는 수신기로부터 받은 CSI 패킷을 서버로 전송한다. 서버에서는 미리 학습해둔 모델에 CSI 데이터를 넣어 실내 신원 식별을 수행하고 그 결과를 웹 소켓 통신으로 유니티에 전달한다. 유니티 클라이언트는 서버로부터 받은 실내 신원 식별 결과를 시각화한다.

3.3.3. 신호 동기화 및 전처리

본 졸업과제의 실내 신원 식별 시스템은 4대의 수신기를 사용했다. 여러 대를 사용함으로써 동기화 과정이 필요하다. 패킷은 무선 환경으로 인한 지연 및 하드웨어 타이머 오차로 인해 4대의 수신기에 제각각 도착한다. 따라서 수신 버퍼 큐를 두어 동일 시점에 Rx 1, 2, 3, 4번 데이터가 모두 모였을 때 비로소 1개의 온전한 4-Rx 통합 데이터로 결합시키는 처리 과정이 필요하다. 결측되거나 어긋난 불완전 패킷은 폐기해버린다. 이후 WiFi 802.11n 규격의 64개 서브캐리어 중 파일럿 신호, 가드 밴드, DC 노이즈 서브캐리어에 해당하는 12개의 서브캐리어를 제고하고 SNR이 우수한 52개의 유효 서브캐리어만 저장한다. 마지막으로 CSI 데이터의 실수부와 허수부로부터 진폭을 추출한다.

3.3.4. 식별 추론

식별 추론 단계에서는 시나리오2에서 수집한 **case1~53**의 모든 데이터 케이스를 **8:2**로 분할하여 학습한 **KNN** 머신러닝 모델을 사용하여 추론한다. 매 패킷마다 추론 결과를 **FIFO** 큐에 순차 삽입하고 최근 **1초(10개 패킷)** 동안의 최빈값을 최종 결과로 채택한다. 해당 방식을 사용한 이유는 추론 모델의 정확도가 **95%~100%**에 달하기에 대부분의 패킷은 정답을 맞추지만 간헐적으로 오답을 시각화하는 경우가 있기 때문이다. 이 오답 시각화는 찰나의 순간이기에 캐릭터나 위치가 아주 잠깐 변경되는 깜빡임 현상이 발생한다. 따라서 윈도우 필터링 방식을 통해 해당 현상을 줄일 필요성이 있었다. 윈도우 필터링을 통해 최종 결과가 추론되면 웹소켓을 통해 **JSON** 형태로 전송한다.

```
json
{
  "person_count": 1,
  "presence": [
    {
      "name": "Minhyun",
      "section": "Zone 2"
    }
  ]
}
```

Fig. 3-44 식별 추론 결과 DTO(json)

3.3.5. 3D 실시간 시각화

유니티 클라이언트에 해당하는 **3D 실시간 시각화** 단계에서는 **NativeWebSocket** 라이브러리를 통해 **JSON** 패킷을 수신한다. **JSON** 데이터를 역직렬화하여 해당 내용에서 구역 및 신원을 추출하고 해당되는 구역 및 캐릭터 객체를 스폰한다.

3.3.6. 시연 결과

3.3.6.1. 3D 가상환경

본 졸업과제의 실내 신원 식별 시스템은 실제 데이터 수집 환경인 자연대연구실험동313-1호를 유니티 3D 가상환경에 1:1로 매핑하여 디지털 트윈 공간을 구축하였다. 실제 연구실의 가로 세로 규격을 측정하여 바닥, 벽, 천장을 1:1 비율로 배치하였다. 출입문과 창문에는 Alpha 블렌딩을 하여 유리창을 투명하게 만들어 뒤가 비치도록 만들었다. 그리고 Metallic/Smoothness 반사율을 튜닝하여 투명 유리 재질감을 살렸다. 도어 프레임과 금속 파티션에는 브러시드 크롬(Brushed Chrome) 금속 재질을 사용하여 뽀하게 비치는 쇠 느낌이 아니라 은은한 철제 금속 질감을 줘서 실제 실험실과 시각적으로 유사하도록 구현하였다.




Fig. 3-45 : 자연대연구실험동313-1호 출입구 가상환경

실제 수집에 사용된 ESP32 보드와 2.4GHz 안테나를 AI 3D 모델링을 통해 제작했다. 313-1호 내에 실제로 설치되었던 송신기 1대와 사분면의 수신기 4대의 위치에 오브젝트를 배치했다.



Fig. 3-46 : ESP32 3D 모델링

실내 천장에는 형광등 3D 모델을 배치하고 URP Lit 셰이더의 HDR Emission 기능을 활성화하여 램프 자체 발광을 연출했다. 또한 포인트 라이트에 실제 연구실 조명과 유사한 색온도 및 부드러운 그림자를 적용하였다. 10Hz 속도로 데이터 수신 및 캐릭터 스폰을 처리해야 하므로 실시간 조명 연산으로 인한 프레임 드랍을 줄이기 위해 실내 정적 구조물에 **Static** 플래그를 지정하고 GPU 라이트매퍼를 활용하여 글로벌 일루미네이션(GI) 라이트맵 및 **Reflection Probe**를 사전 베이킹하였다.




Fig. 3-47 : 자연대연구실험동313-1호 가상환경 전경

공간 전체의 인원 분포를 사각지대 없이 한눈에 파악할 수 있는 탐뷰 카메라를

배치하였다. 필요에 따라 실내 세부 상황을 입체적으로 모니터링하기 위해 CCTV 처럼 다중 시점 전환 기능을 구현했다. 탐류 카메라는 방 천장 모서리마다 배치하여 총 4개가 배치되어있다. 키보드 숫자 번호 1, 2, 3, 4키를 사용하여 카메라 시점을 옮길 수 있다. 뿐만 아니라 마우스를 통해 해당 위치에서 정해진 각도 내로 시야를 옮길 수 있다.




Fig. 3-48 : 1번 카메라 기본 시점




Fig. 3-49 : 1번 카메라에서 오른쪽으로 고개를 돌린 경우




Fig. 3-50 : 2번 카메라 기본 시점

3.3.6.2. 3D 캐릭터

실내 신원 식별 시스템에서는 4대의 수신기로부터 추론된 인물 식별 결과를 3D 가상환경에 직관적이고 현실감 있게 표현하기 위해 인물별 전용 3D 캐릭터 모델을 사용하였다. 해당 3D 캐릭터 모델은 유니티 에셋 스토어의 무료 에셋이다.



(한별)



(민경)



(민현)



(조교)

Fig. 3-51 : 3D 캐릭터 모델링

해당 3D 캐릭터 모델은 대기 동작 애니메이션을 제공하지 않아 T 자세로 부자연스럽게
서 있다. 자연스러운 대기 동작을 구현하기 위해 어도비 믹사모(Adobe Mixamo,
mixamo.com)에서 Idle animation을 구해 Loop 형태로 캐릭터 모델에 적용시켰다.



Fig. 3-52 : 대기 동작 애니메이션 적용

3.3.6.3. 시연

본 졸업과제에서 구현된 실내 신원 식별 시스템은 시연을 하기 위한 제약 조건이 존재한다. 데이터를 수집한 장소, 시간, 환경이 동일해야하므로 실시간으로 시스템을 시연하기에는 까다롭다. 따라서 미리 수집된 데이터와 학습된 모델을 통해 시연하기로 했다. 본 시연에서는 시나리오2의 **day1**을 CSI 데이터로 사용하며 **case1** 부터 **case53**까지 차례로 3초간 추론 모델의 입력값으로 사용한다.



Fig. 3-53 : 1번 카메라에서 본 case9(민경, 구역4)



Fig. 3-54 : 2번 카메라에서 본 case28(조교 구역2, 민경 구역4)



Fig. 3-55 : 3번 카메라에서 본 case35(조교 구역2, 민현 구역1)



Fig. 3-56 : 4번 카메라에서 본 case39(조교 구역3, 한별 구역4)

4. 연구 결과 분석 및 평가

4.1 시나리오 1 결과

시나리오 1에서는 단일 송수신기 환경에서 Wifi CSI 데이터를 이용한 사람 및 위치 식별 가능성과 1인/2인 데이터의 합성 및 분리 가능성을 확인하였다. 먼저 KNN 모델을 이용하여 사람 및 위치를 식별한 결과 각 평균 95.39%, 99.73%로 높은 정확도를 보여 CSI 데이터로 사람 및 위치 식별이 가능함을 확인하였다. 하지만 현재 학습 모델로는 수집된 데이터 범위 내에서만 추론이 가능하므로 여러 데이터 합성 방법을 시도하였다. 그러나 1인 CSI 데이터를 이용한 2인 CSI 합성에서 23.33%의 낮은 정확도를 보였는데, 원본 2인 데이터끼리 형태가 매우 유사해 실제 정답 case를 구분하는 데 어려움이 있었기 때문이다. 반면 2인 CSI를 분리하는 실험에서는 평균 85.13%의 정확도를 보여 수집된 범위 내에서는 KNN 학습 만으로 2인 데이터 분리가 가능함을 확인하였다. 또한 비동일 날짜 데이터를 이용한 학습에서는 평균 44.72%의 낮은 정확도를 보여 시간 변화에 따라 기존에 학습된 모델의 성능이 저하되는 점을 확인하였다.

4.2 시나리오 2 결과

4.2.1 KNN을 이용한 분석

시나리오 2에서는 시나리오1에서 확인된 수집된 범위 밖에서의 사용자 조합 식별 한계를 개선하기 위해 수신기를 4개로 확장한 다중 송수신기 환경을 구성하여 사람 및 위치 식별과 2인 데이터 합성/분리를 수행하였다. 먼저 시나리오1에서 진행한 KNN 모델을 똑같이 적용한 결과 사람 및 위치 식별에서 각 98.89%, 99.25%의 높은 정확도를 보였다. 이를 통해 다중 송수신기 환경이 사람 식별 성능 향상에 기여함을 확인하였다. 이후 2인 데이터 합성에서 배경 차감 기반의 KNN 방법을 적용한 결과 최대 47.22%의 정확도를 확인하였다. 시나리오1의 결과인 23.33%보다 결과가 향상되었지만 여전히 2인 데이터 간의 형태가 서로 유사하여 case를 정확하게 구분하기 어렵고, 실제 시스템에 적용하기에는 여전히 낮은 성능을 보였다. 또한 2인 데이터의 고유한 특징을 찾기 위한 호흡수 분석도 수행하였다. 하지만 1인 데이터 안에서도 여러 주파수 피크가 나타났고 추출된 값이 실제 호흡수인지 확인하기 어려웠다. 따라서 호흡수만으로 사용자를 구분하기에는 신뢰성이 부족하고 별도의 측정 장비를 통한 검증이 필요하다는 한계가 존재했다.

4.2.2 딥러닝을 이용한 분석

기존 KNN 기반 방법의 한계를 개선하기 위해 CSI 데이터의 복잡한 특징을 자동으로 학습할

수 있는 딥러닝 기반 모델을 적용하였다. 초기 2D CNN에서는 2인 CSI 합성에서는 최대 30%, 분리에서는 최대 10%의 낮은 성능을 보였다. 이에 합성과 분리를 동시에 수행하는 Dual Network를 구성하였고 평균 정확도는 22.5%로 나타났다. 이후 Cycle 구조를 추가하여 합성과 분리 결과가 서로 피드백되도록 구성한 결과 평균 정확도가 32.5%로 향상되었다. 또한 4개의 수신기별로 모델을 구성하여 각 수신기에 적용한 결과 평균 35%까지 성능을 개선시킬 수 있었다. 마지막으로, 측정된 데이터는 움직임 없이 가만히 서 있는 정적인 데이터이기에 시간축의 변화가 크지 않다는 점을 고려하여 Cycle과 4-Rx 구조는 유지한 채 차원만 1D CNN 구조로 변경하였다. 변경된 모델은 최고 35%의 정확도를 기록하였다.

종합적으로 시나리오 2에서는 단일 송수신기를 다중 송수신기로 확장하고 딥러닝 구조를 단계적으로 적용하면서 합성/분리 모델의 성능을 개선하였으나 2인 CSI 데이터 간 높은 유사성으로 인해 새로운 사용자 조합을 식별하는 것은 여전히 한계가 존재함을 확인하였다.

4.3 종합 평가

본 연구의 실험 결과를 종합해보면 WiFi CSI 데이터를 이용한 사람/위치 식별 자체는 수집된 범위 내에서 비교적 높은 정확도로 수행이 가능함을 확인하였다. 특히 단일 수신기 환경에서도 사람 95.39%, 위치 99.73%의 높은 정확도가 나타났고, 다중 수신기 환경에서는 사람 98.89%, 위치 99.25%의 정확도로 수신기를 늘려 공간 정보를 확보한 것이 사람 식별 성능 향상에 기여했음을 확인하였다. 반면 본 연구의 목표인 수집되지 않은 사용자 조합에 대한 CSI 합성 및 분리는 기존의 단순 연산이나 KNN만으로는 충분한 성능을 얻기 어려웠다. 시나리오 1의 합성 정확도는 23.33%, 시나리오 2의 KNN기반 합성은 47.22%로 시나리오1에 비해 시나리오2에서 성능이 개선되었지만 여전히 충분한 성능을 얻지는 못하였다. 이후 CSI 신호의 세세한 특징을 학습시키기 위해 딥러닝 모델을 이용하였다. 단계적으로 Dual Network, Cycle, 4-RX구조를 도입하여 점진적으로 성능이 개선되었지만 최종적으로 정답 Case를 정확히 매칭하는데는 한계가 있었다. 이런 결과의 주요 원인으로는 다중경로 환경에서 발생하는 CSI 신호의 복잡한 변화와 2인 데이터 간의 높은 유사성을 원인으로 들 수 있다. 따라서 본 연구에서는 WiFi CSI를 이용하여 사람/위치 식별 가능성을 검증하였고 수집 되지 않은 사용자 조합을 대상으로 CSI 합성/분리 문제를 해결하기 위해 여러 방법을 단계적으로 시도해보며 해당 문제의 가능성과 한계를 확인하였다는 점에 의의를 둔다.

5. 결론 및 향후 연구 방향

5.1 결론

본 연구에서는 ESP32-c6을 이용하여 WiFi CSI 데이터를 수집하여 이를 기반으로 사람 및 위치 식별을 수행하였다. 시나리오 1에서는 단일 송수신기 환경에서 CSI 데이터를 이용하여 수집된 범위 내 사람과 위치 식별이 가능함을 확인하였다. 이후 수집되지 않은 사용자 조합에 대해서도 식별이 가능한지 확인하기 위해 시나리오 2의 다중 수신기 환경으로 확장하여 1인 CSI와 2인 CSI의 합성/분리 가능성을 확인하였다. 또한 CSI의 복잡한 특징을 학습시키기 위해 딥러닝 모델에 CNN, Dual Network, Cycle, 4-RX 구조를 단계적으로 적용하였다. 실험 결과 점진적으로 성능이 개선됨을 확인하였으나 여전히 2인 CSI 데이터 간의 높은 유사성으로 인해 정답 case를 정확하게 식별하는 데는 한계가 존재했다. 종합적으로 본 연구에서는 WiFi CSI가 실내 사람 및 위치 식별에 활용될 수 있음을 확인하고 다중 사용자 환경에서는 수집된 범위 밖의 사용자 조합을 식별하기 위해 다양한 방법으로 분석해보았다. 비록 데이터의 유사성과 데이터 부족, 적절한 모델을 찾지 못하는 등 여러 한계로 인해 사용자 식별에 높은 성능을 내지 못했지만 본 연구에서 확인한 결과와 한계를 바탕으로 향후 보다 많은 데이터를 수집하고 효과적인 모델 구조와 학습 방법을 적용한다면 합성 및 분리 성능을 지속적으로 향상시킬 수 있을 것으로 기대된다. 또한 성능 개선을 통해 실제 환경에서도 활용 가능한 WiFi CSI 기반 다중 사용자 식별 시스템으로 발전할 수 있을 것이다.

5.2 향후 연구 방향

향후 연구에서는 먼저 데이터의 양을 늘리고 더 많은 사용자 조합을 수집할 필요가 있다. 본 연구에서는 각 시나리오별 데이터를 4~5일 동안 수집하여 학습에 활용했기 때문에 모델이 다양한 데이터 변화를 충분히 학습하기에는 한계가 있다. 또한 2인 데이터를 측정할 때 특정한 사용자가 무조건 포함되는 형태로 2인 데이터를 측정하였다. 이런 방식으로 인해 서로 다른 case간 CSI 신호가 유사하게 나타났을 가능성이 있다. 향후에는 특정 사용자에 대한 의존성을 줄이고 다양한 사용자 조합을 균등하게 구성하여 사용자 조합 자체 차이가 학습에 충분히 반영될 수 있도록 여러 조합 데이터를 수집할 필요가 있다. 또한 CSI 데이터의 높은 유사성을 해결할 수 있는 모델 개발이 필요하다. 현재 모델은 CSI간 전체적인 형태가 유사한 경우 정답 case를 정확하게 구분하는 데 한계가 있었다. 따라서 향후에는 CSI 신호에서 발생하는 미세한 차이와 사용자별 특징을 보다 효과적으로 추출하고 유사한 데이터 사이에서도 사용자를 구분할 수 있는 새로운 특징 학습 및 딥러닝 모델을 제시하는 방향으로 연구를 발전시킬 필요가 있다. 마지막으로 현재 구현된 유니티 시스템은 이미 수집된 CSI 데이터와 학습된 case를 기반으로 사용자를 식별하는 방식으로 동작하므로

새로운 CSI 데이터가 실시간으로 입력되는 환경에는 제한이 있다. 향후 모델의 합성/분리 성능을 개선시켜 새로운 사용자 조합에 대한 식별 성능을 높이고 실시간으로 수집되는 CSI 데이터를 모델이 즉시 분석할 수 있도록 시스템을 확장할 필요가 있다. 이를 통해 CSI 데이터 수집부터 모델 기반 사용자 식별, 유니티를 통한 결과 시각화까지 실시간으로 수행할 수 있고 실제 환경에 적용 가능한 시스템으로 발전시키는 것을 목표로 한다.

6. 참고 문헌

- [1] F. Adib and D. Katabi, "See-through walls with Wi-Fi!," in Proceedings of the ACM SIGCOMM 2013 Conference on SIGCOMM, 2013, pp. 75-86.
- [2] Y. Ma, G. Zhou, and S. Wang, "Wi-Fi sensing with channel state information: A survey," ACM Computing Surveys (CSUR), vol. 52, no. 3, pp. 1-36, 2019.
- [3] M. Kaneko, T. Higuchi, Y. Watabe, and T. Ohtsuki, "Wi-CaL: Wi-Fi Sensing and Machine Learning-Based Device-Free Crowd Counting and Localization," IEEE Access, vol. 10, pp. 45311-45323, 2022.
- [4] O. Custance, S. Khan, and S. Parkinson, "Why commodity Wi-Fi sensors fail at multi-person gait identification: A systematic analysis using ESP32," arXiv preprint arXiv:2601.02177, 2026.
- [5] G. Yin, J. Zhang, G. Shen, and Y. Chen, "FewSense, towards a scalable and cross-domain Wi-Fi sensing system using few-shot learning," IEEE Transactions on Mobile Computing, vol. 23, no. 1, pp. 453-468, 2024.